Визуализация и исследование данных — на примере «Война и мир»

Министерство образования Иркутской области · Сиб. отделение РАН · Региональная конференция «Наука. Технологии. Интеллект»

Выполнила: Косова Лада Петровна, ученица 11 «Д», МАОУ «Ангарский лицей №1». Руководитель: Косов Пётр Борисович.

Введение — цель и задачи

Цель: создать открытый и воспроизводимый конвейер для анализа текста и генерации визуальных пособий для крупных произведений.

Задачи:

- Разработать формат и конвенции для визуализаций.
- Автоматизировать сбор и нормализацию данных из текста.
- Построить визуализации, удобные для исследования текста.
- Опубликовать результаты в открытом доступе (статический сайт).

Система разработки (включая телефон)

Проект можно разрабатывать и запускать в лёгком окружении (Termux на Android) или на ПК. Ключевые инструменты, использованные в процессе:

- Markor — заметки/черновики
- Termux — среда на телефоне
- GitHub — репозиторий и публикация
- Agent PI — помощник при генерации кода (использовался для ускорения разработки)
- Python — анализ и генерация CSV/JSON
- JavaScript (Vite + ECharts) — статическая витрина

(Подсказка: проект фиксирует параметры прогона в run_metadata.json — это делает результаты воспроизводимыми между машинами.)

Сбор данных — пайплайн

Пайплайн формирует готовые для визуализации таблицы/JSON:

- Нормализация (UTF-8, кавычки, тире, многоточия)
- Токенизация и лемматизация
- Разбиение на предложения, абзацы, главы и диалоги
- Выделение кандидатов на именованные сущности (правилами)
- Подсчёт метрик: частоты, hapax, Yule/Honore, тональность, пунктуация
- Экспорт в CSV/JSON (tokens.csv, characters.csv, cooccurrence_edges.csv и др.)

Витрина и визуализация

Frontend — статический Vite-сайт, который загружает готовые CSV/JSON из `site/public/data/`. Это даёт простую и надёжную публикацию без отдельного API.

Преимущества: лёгкий развёртывание, reproducible artifacts, простота отката и тестирования.

Реализация кода с помощью агента

В разработке использовался агент PI в роли помощника по коду. Ключевые наблюдения:

- Агент эффективен при наличии подробной спецификации — пишет много кода быстро.
- Нужен тщательный код-ревью: автогенерированный код может нарастить когнитивную долговую нагрузку.
- Агент иногда усложняет структуру репозитория — после генерации требуется рефакторинг.

Частотное ядро (frequency core)

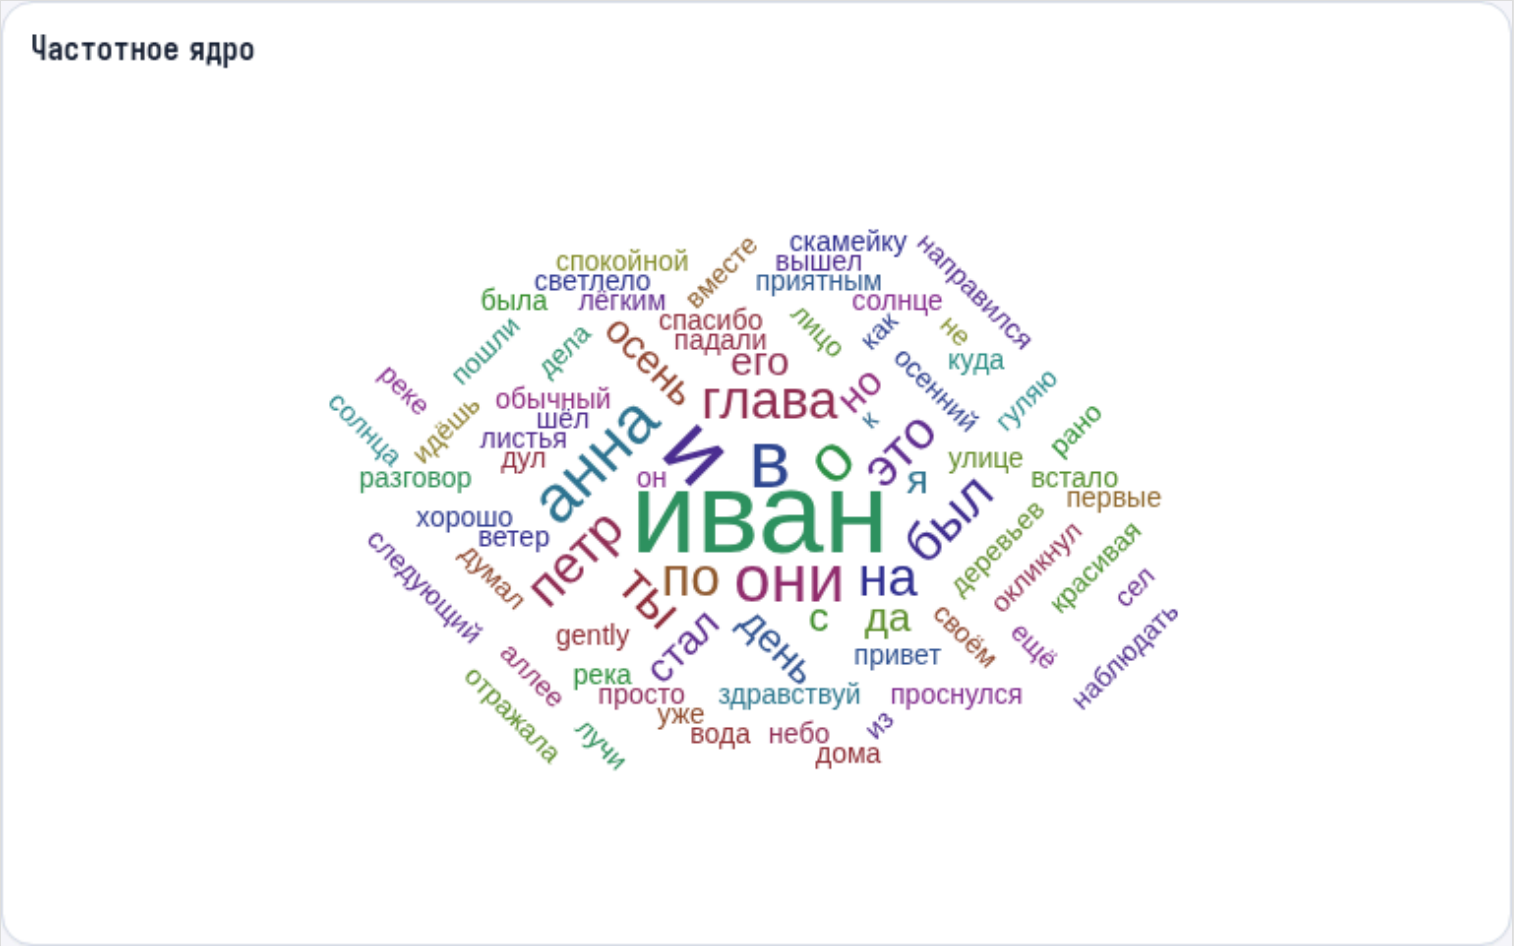

График показывает распределение частот токенов после очистки и фильтрации стоп-слов. Помогает быстро увидеть доминирующие слова и общую лексику произведения.

Top tokens — топ слов

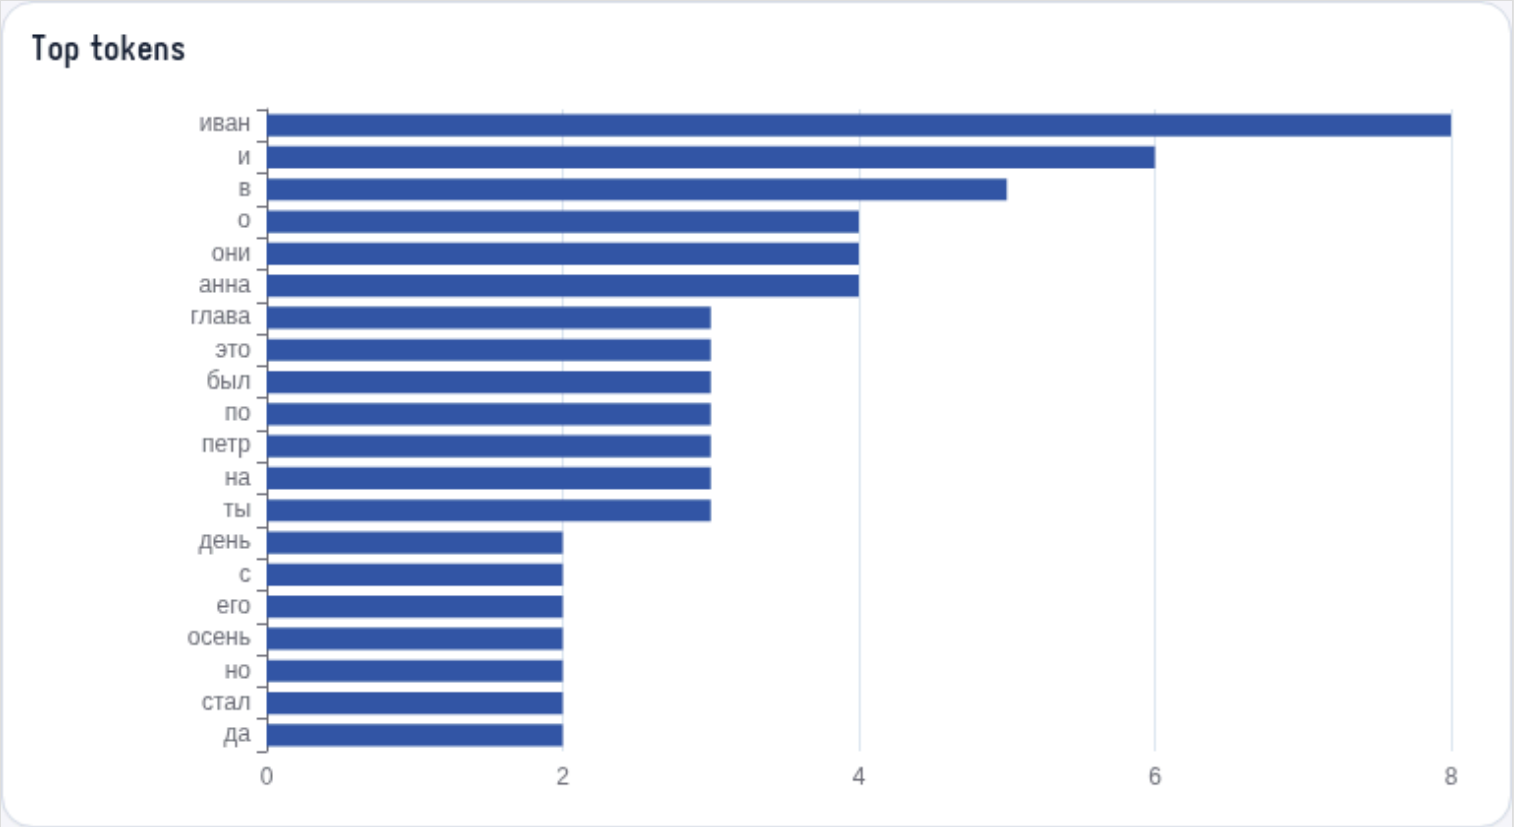

Барчарт с топ-словами по частоте. Используется для быстрой инспекции ключевых лексем и проверки корректности нормализации/лемматизации.

Ритм по главам

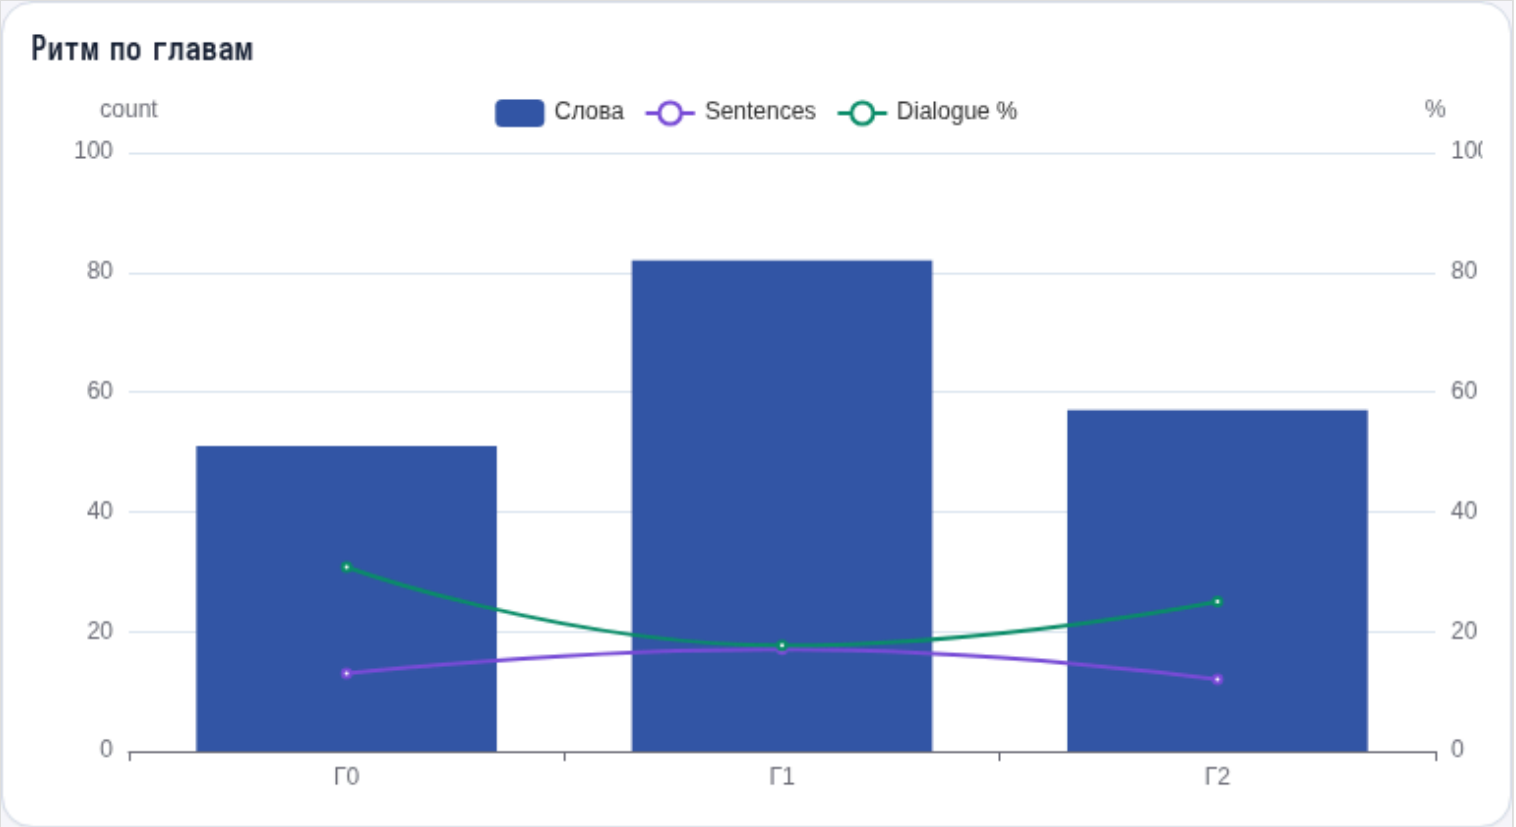

Таймлайн/диаграмма, показывающая плотность событий/текстовую активность по главам — помогает находить пики динамики и структурные особенности.

Тональность по главам

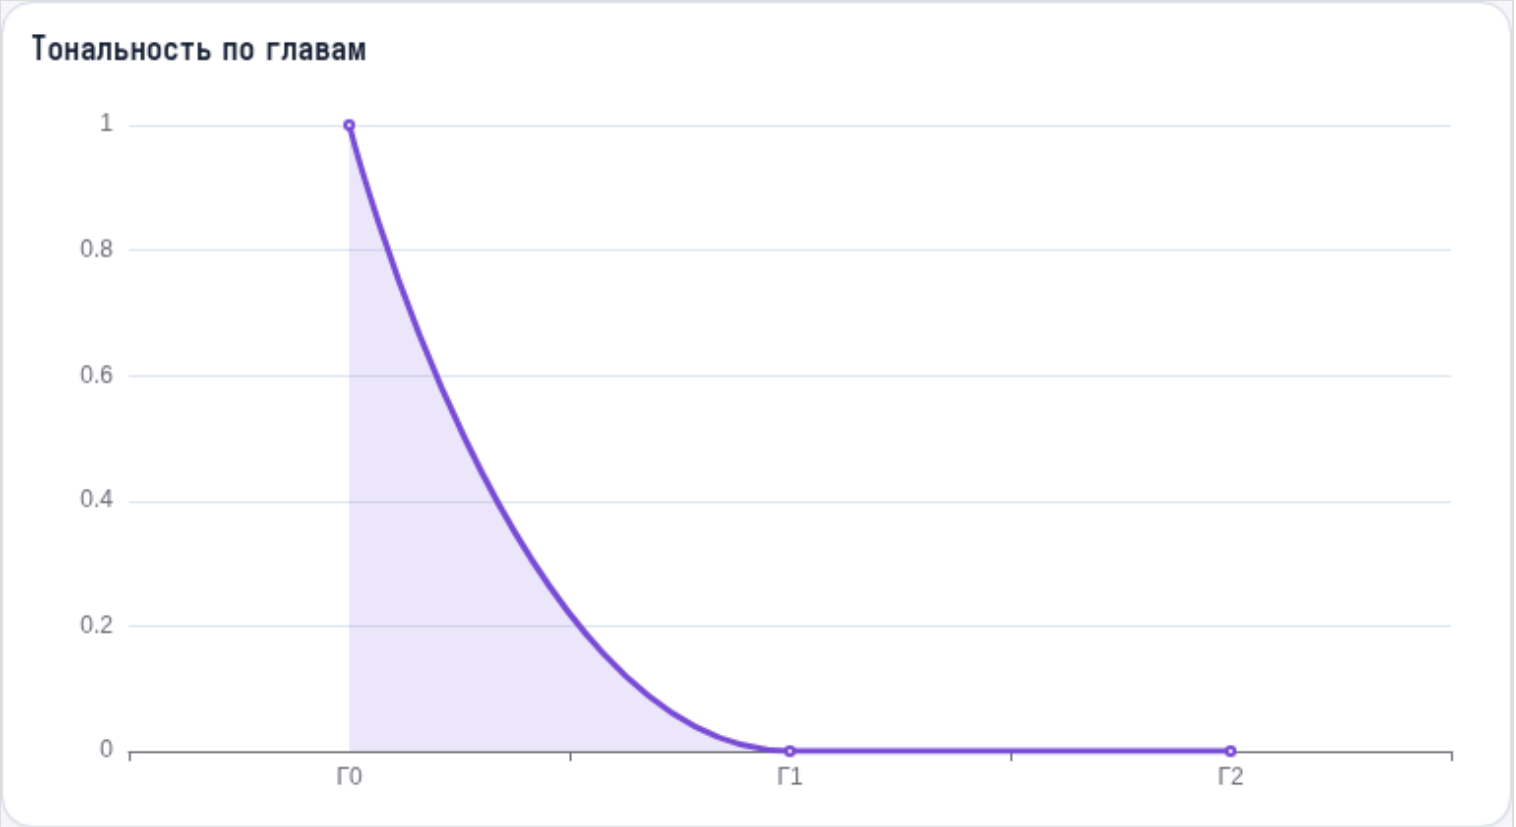

Линейный график тональности (лексикон-based). Оценка приближённая, но полезна для выявления эмоциональных смен в тексте.

Сеть персонажей

Граф ко-встречаемости персонажей: ребра — совместные появления в окне контекста, вес — частота. Позволяет визуально выделить центральных и второстепенных персонажей.

Список персонажей

Персонажи

name	occurrences	num_chapters	context_sample
Иван	7	3	gently дул в лицо. Иван шёл по улице и дума
Анна	3	2	ы кто? — Меня зовут Анна. Я здесь новая.
Петр	2	1	ван! — окликнул его Петр. — Здравствуй, Петр
Осень	2	2	шь? — Просто гуляю. Осень красивая.

Таблица обнаруженных персонажей и их частоты. Нерегулярности в именах — следствие эвристического NER; требует дополнительной ручной валидации.

Hapax legomena

Hapax

token	count
gently	1
а	1
аллее	1
была	1
было	1
ветер	1
вещи	1
взгляд	1
вместе	1

Список слов, встречающихся единожды. Полезно для изучения уникальной лексики и артефактов разметки.

Метаданные прогона

Метаданные прогона

key	value
book_id	test_book
start_time	2026-05-11T18:30:33.264495
end_time	2026-05-11T18:30:33.264530
duration_seconds	0.000035
lang	ru
ner_mode	heuristic
sentiment_mode	lexicon

run_metadata.json фиксирует параметры и время прогона — это ключ к воспроизводимости (версии, флаги, время).

Пунктуация и структура

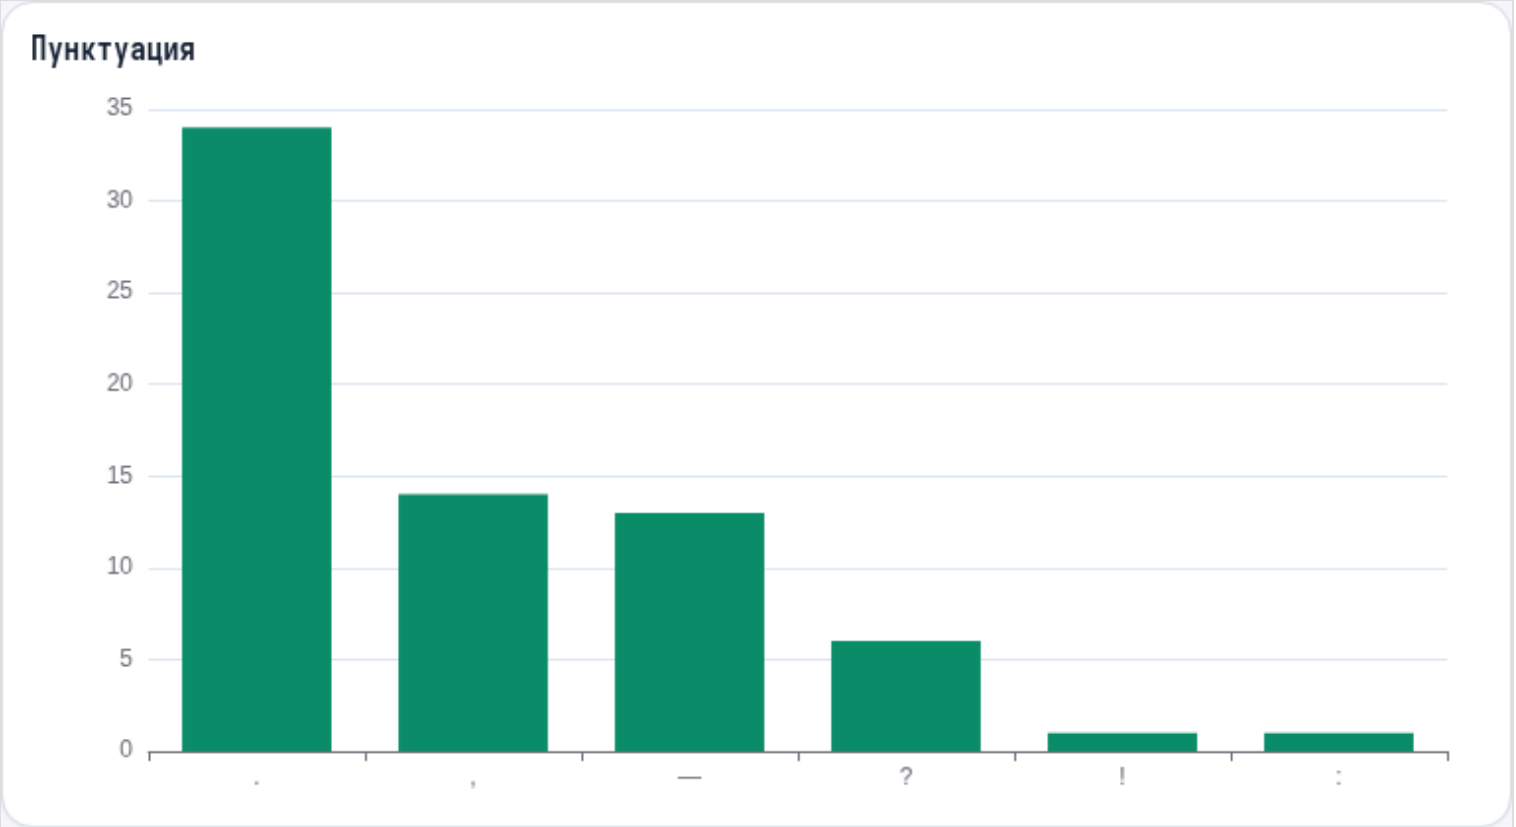

Анализ частот пунктуации по главам помогает обнаружить диалоги, паузы и изменение стиля повествования.

Стиль: radar

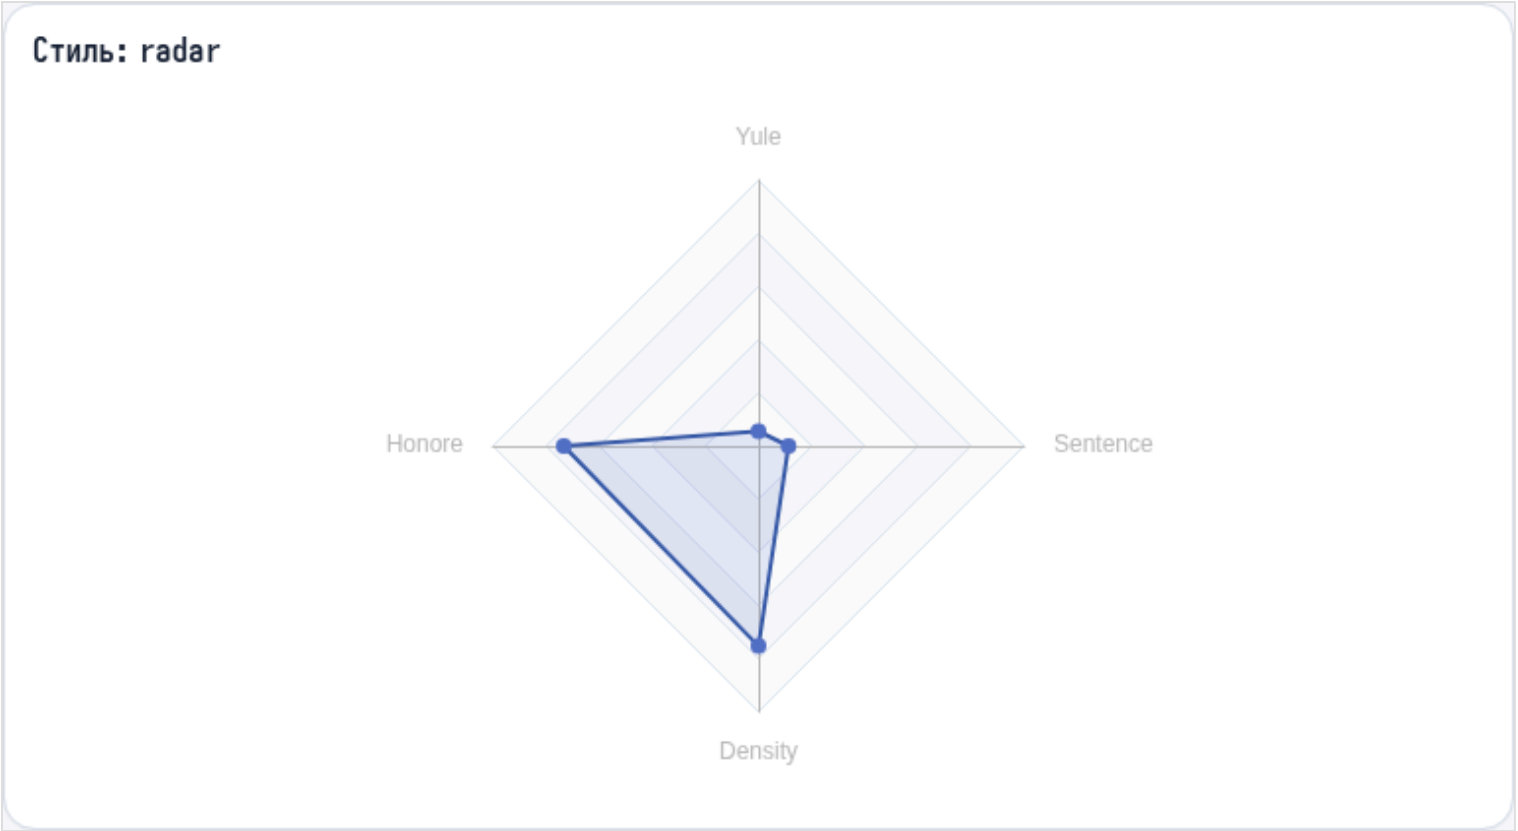

Радар-диаграмма показывает сжатые метрики по главам/секциям (лексическая плотность, длинна предложений и пр.).

Главы: words × sentences

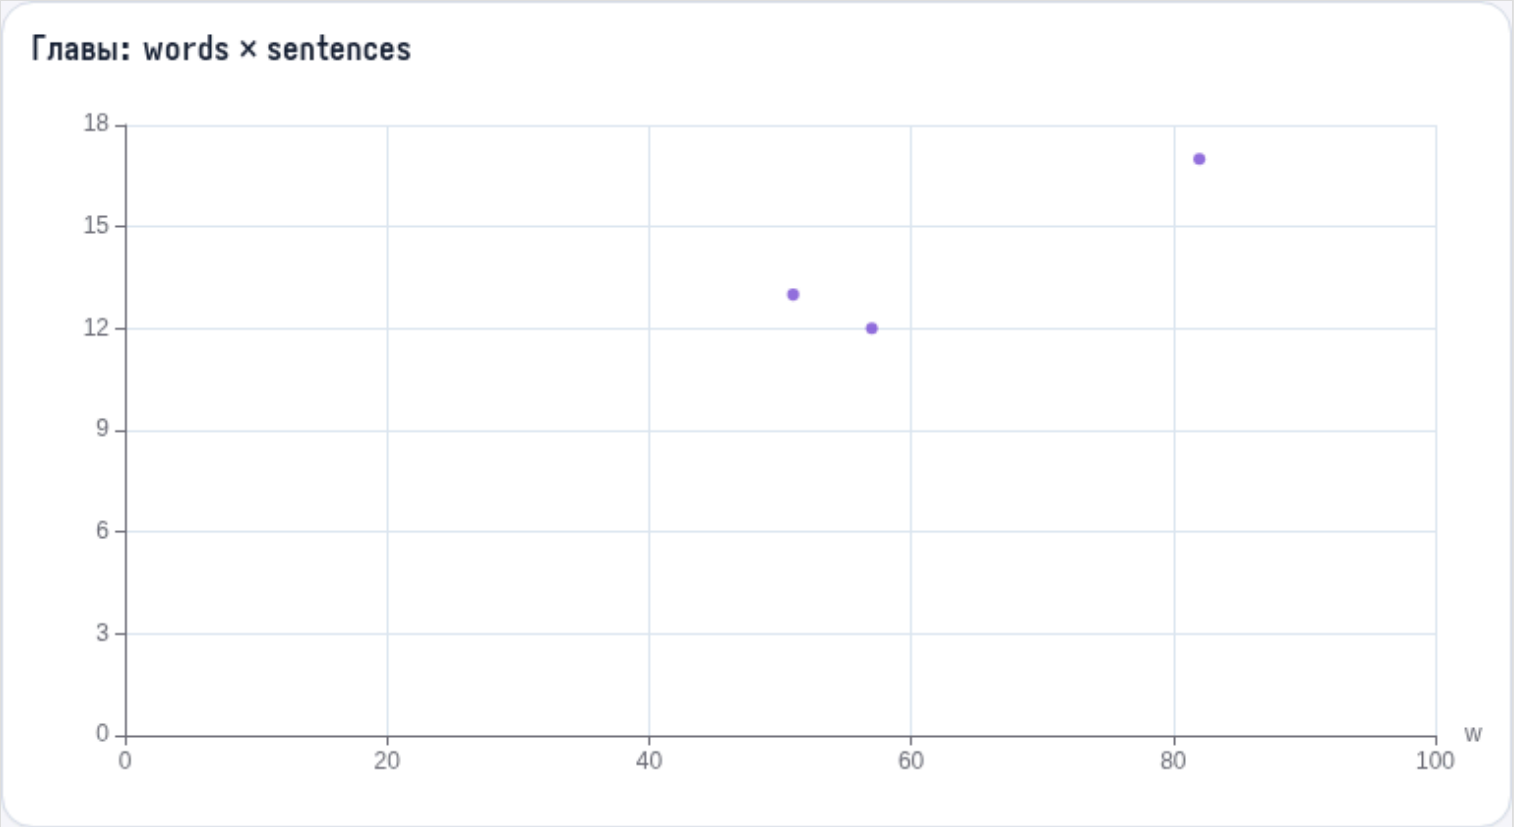

Scatter plot: соотношение слов и предложений в главах — помогает находить аномально длинные/короткие главы.

Персонажи × главы

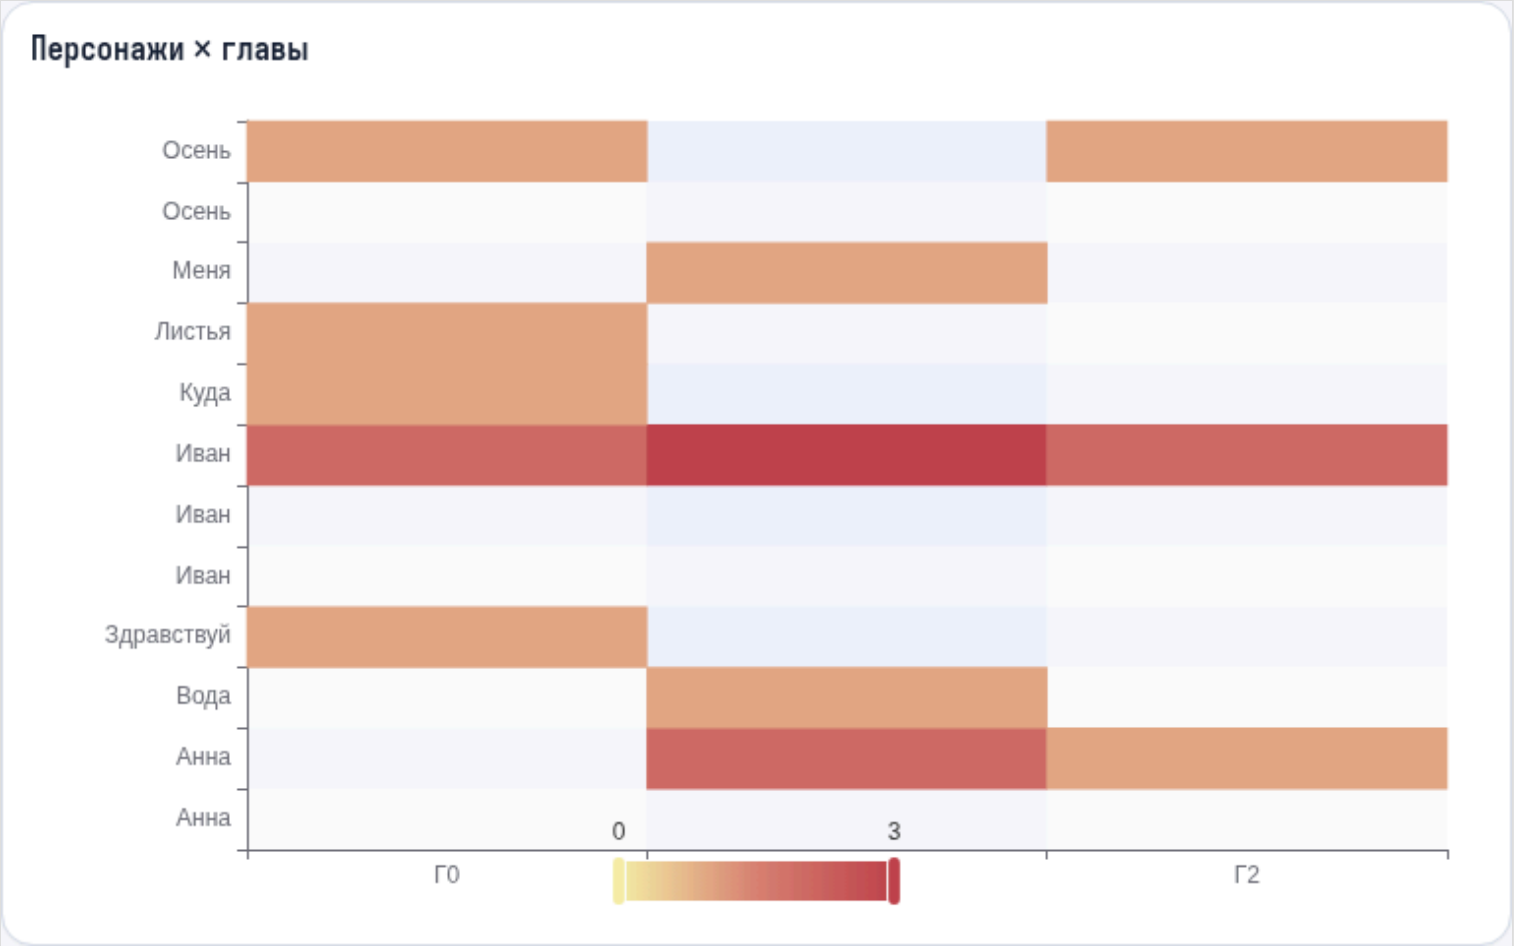

Тепловая карта появления персонажей по главам — удобно для отслеживания арок и смен фокуса на персонажей.

Токены × главы

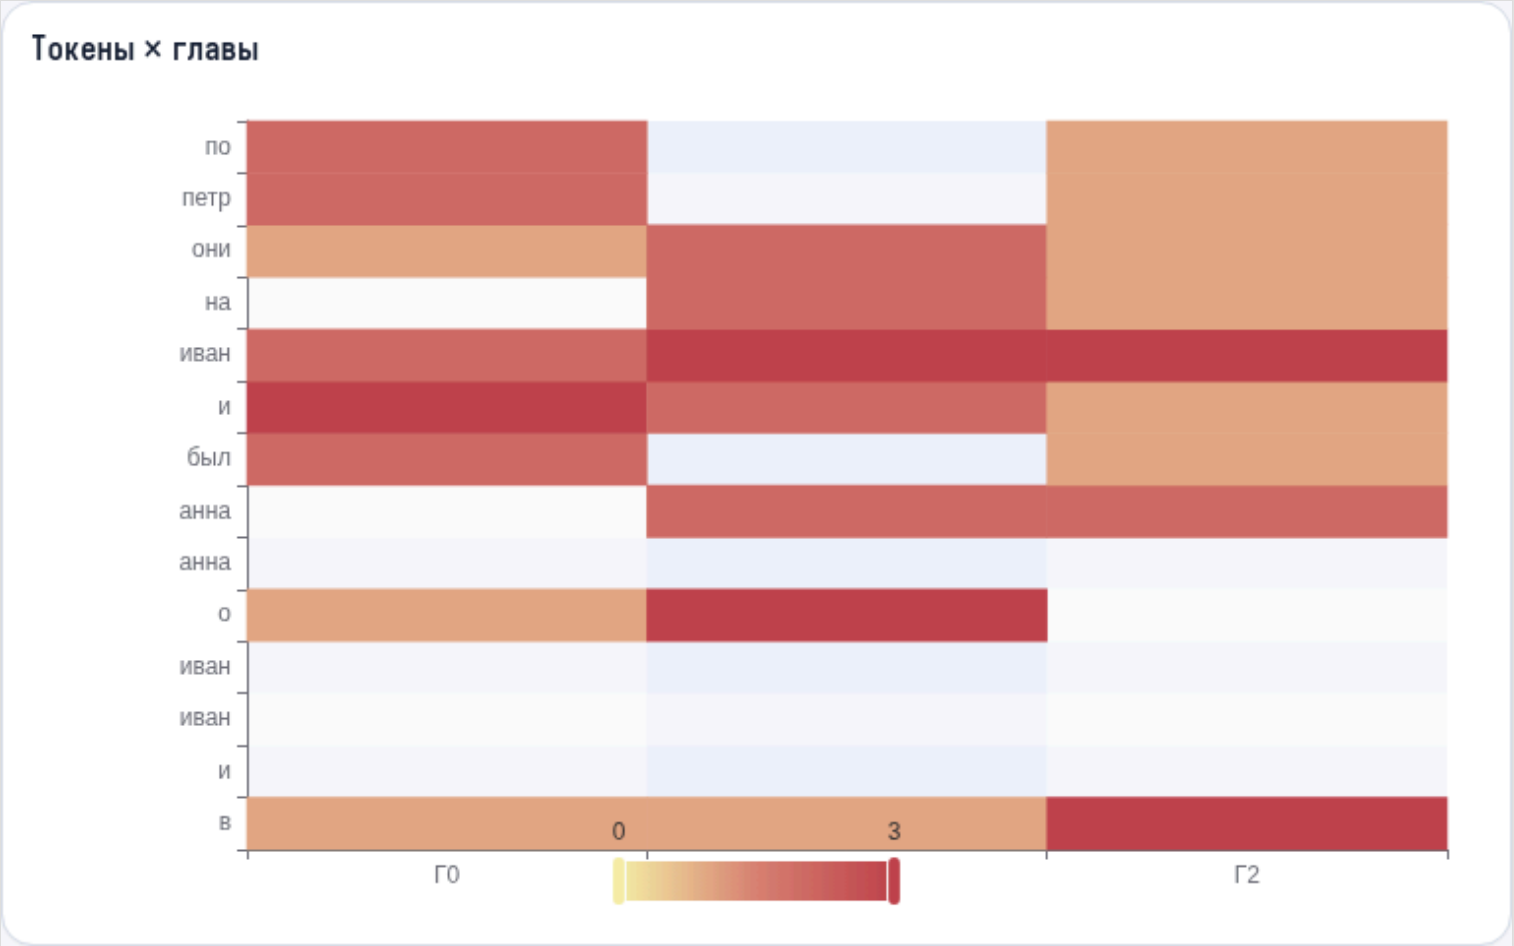

Тепловая карта распределения частот ключевых токенов по главам — полезно для тематического картирования.

Zipf: rank × frequency

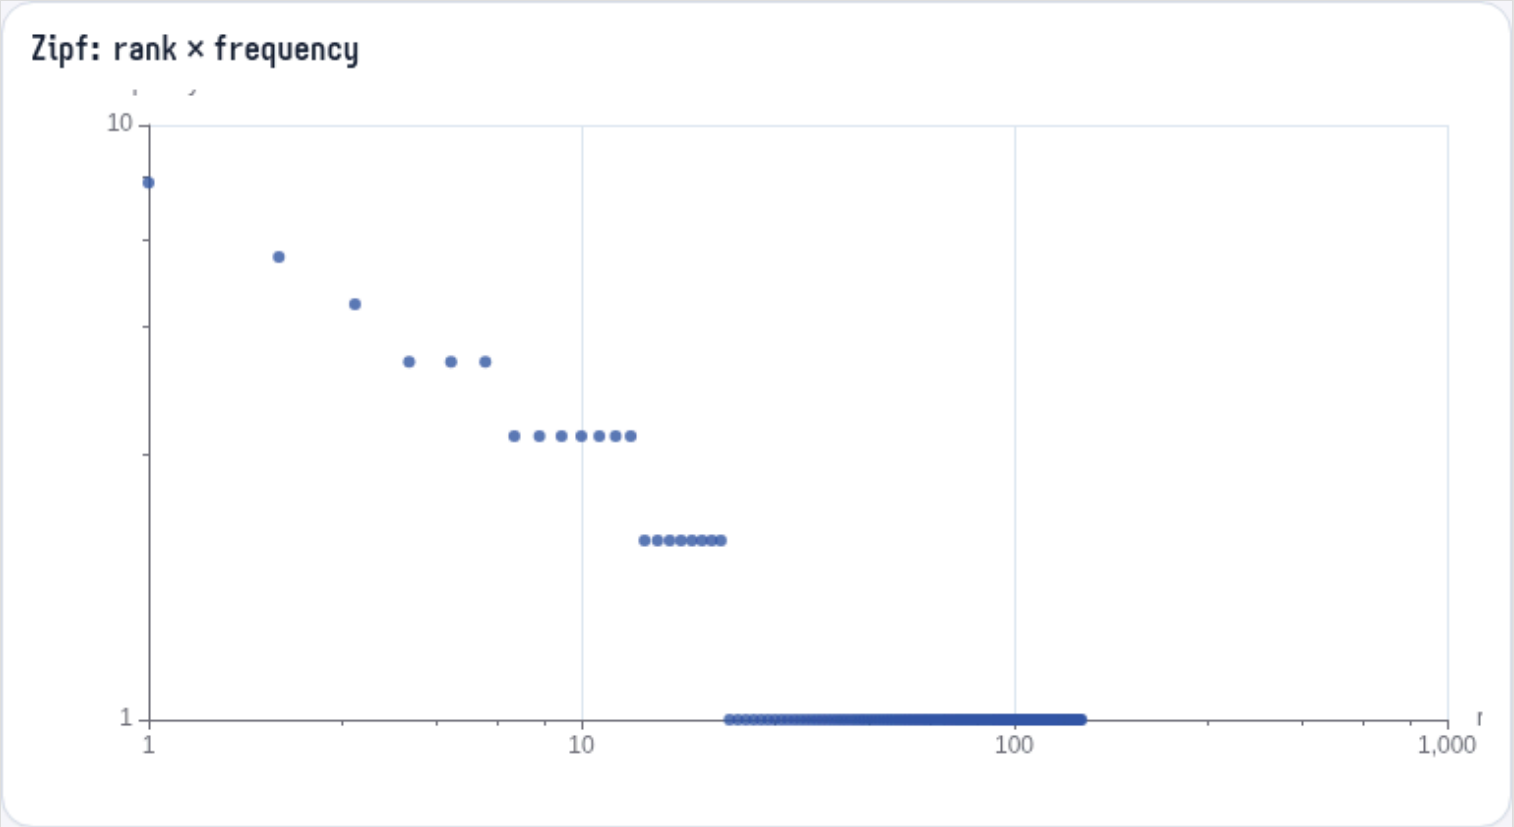

Граф ранга и частоты токенов (закон Ципфа). Проверка ожидаемого распределения и качества токенизации.

Реализация и выводы

Мы показали рабочий конвейер: от текста до визуализаций и статической витрины. Артефакты хранятся в `outputs/<book_id>/` и экспортируются в `site/public/data/`.

Дальше: улучшение NER, валидация персонажей, сравнение разных изданий и масштабирование на корпус.

Спасибо за внимание

Вопросы и предложения — обсуждаем. Доп. материалы и код — в репозитории.