Визуализация и исследование данных — на примере «Война и мир»

Министерство образования Иркутской области · Сиб. отделение РАН · Региональная конференция «Наука. Технологии. Интеллект»

Выполнила: Косова Лада Петровна. Руководитель: Косов Пётр Борисович.

Визуализация и исследование данных при анализе классической литературы на примере романа “Война и мир”

Министерство образования Иркутской области
Министерство по молодежной политике Иркутской области
Сибирское отделение Российской академии наук
Региональная конференция проектно-исследовательских работ
«Наука. Технологии. Интеллект»
Для учащихся 8-11 классов
общеобразовательных учреждений Иркутской области

Выполнила: Косова Лада Петровна
ученица 11 «Д» класса , МАОУ «Ангарский лицей №1»
МАОУ «Ангарский лицей № 1»
Руководитель проекта: Косов Пётр Борисович

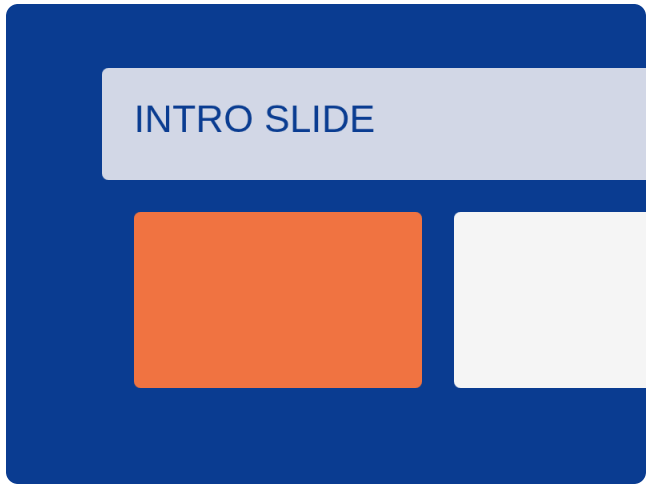

Введение

Цель: создать открытый и воспроизводимый способ анализа текста и построения визуализаций для крупного литературного произведения.

Задачи:

- разработать понятный формат визуализаций;
- автоматизировать сбор и подготовку данных из текста;
- построить наглядные визуализации;
- опубликовать результат в открытом доступе.

Штудия с роботом и рукописью

Система разработки на телефоне

Инструменты:

- **Markor** — черновики и заметки.
- **Termux** — рабочая среда на Android.
- **GitHub** — хранение и публикация проекта.
- **PI** — помощник при написании кода.
- **Python** — обработка текста и данных.
- **JS** — веб-витрина визуализаций.

Стол с ноутбуком, терминалом и роботом-помощником

Сбор данных

Пайплайн:

- нормализация текста (UTF-8, единые кавычки и тире);
- разбиение на токены;
- разбиение на предложения, абзацы, главы и диалоги;
- лемматизация слов;
- выделение имен собственных и их связей в тексте;
- подсчет метрик сложности и тональности;
- вывод данных в таблицы JSON и CSV.

Пайплайн обработки текста с роботом и карточками токенов

Визуализация

- Визуализации сделаны на JavaScript без API и внешних серверов.
- Проект выложен в GitHub и запускается локально как статический сайт.

Литературный рабочий стол с ноутбуком и графиками

Реализация кода при помощи агента.

В разработке я использовала агента PI.

- Ему нужна максимально подробная спецификация.
- Он быстро пишет большой объем кода.
- Его нужно внимательно читать, чтобы не накапливать когнитивный долг.
- Он склонен усложнять структуру репозитория.
- После генерации нужен рефакторинг.

Автор и робот за совместной работой над кодом

Спасибо за внимание.

Дополнительные материалы, визуализации и код доступны в репозитории.

Архив, книги и робот с итоговым отчетом

Частотное ядро (frequency core)

График показывает, как распределяются частоты токенов после очистки и удаления стоп-слов. Он помогает быстро увидеть ядро лексики произведения.

Top tokens — топ слов

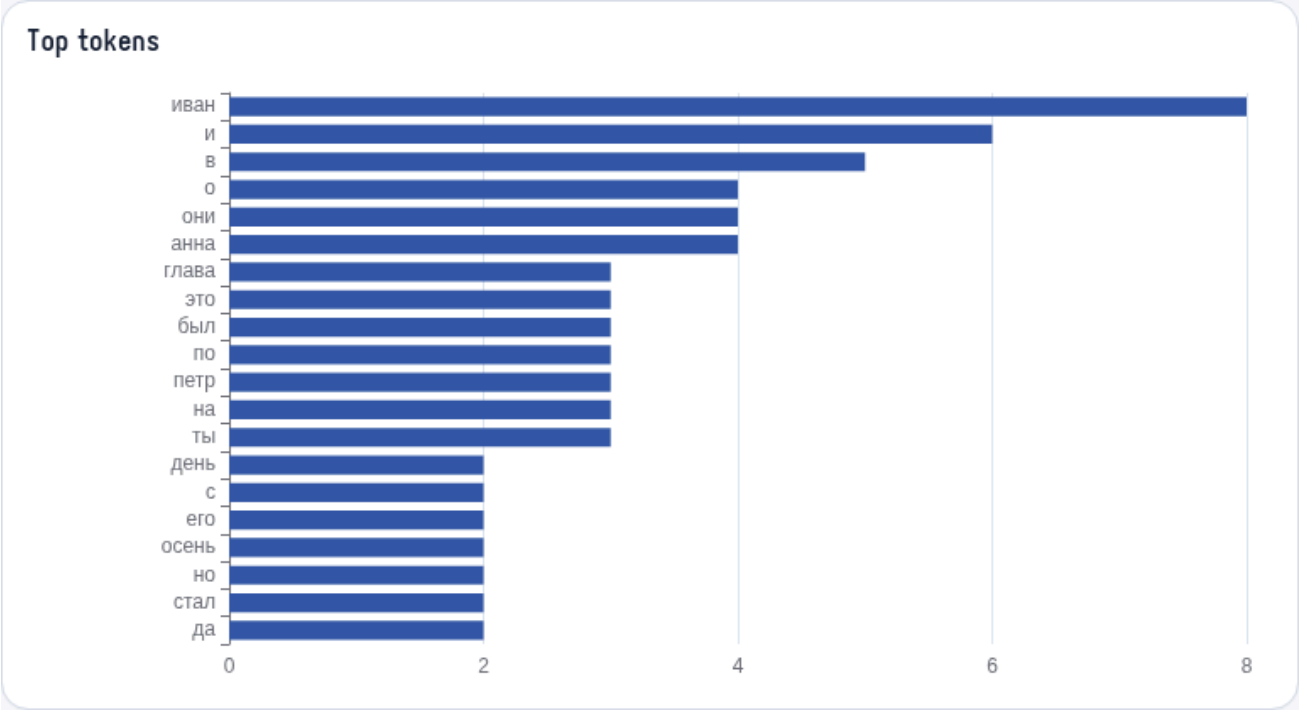

Барчарт с самыми частотными словами. Он нужен для быстрой проверки нормализации и лемматизации.

Ритм по главам

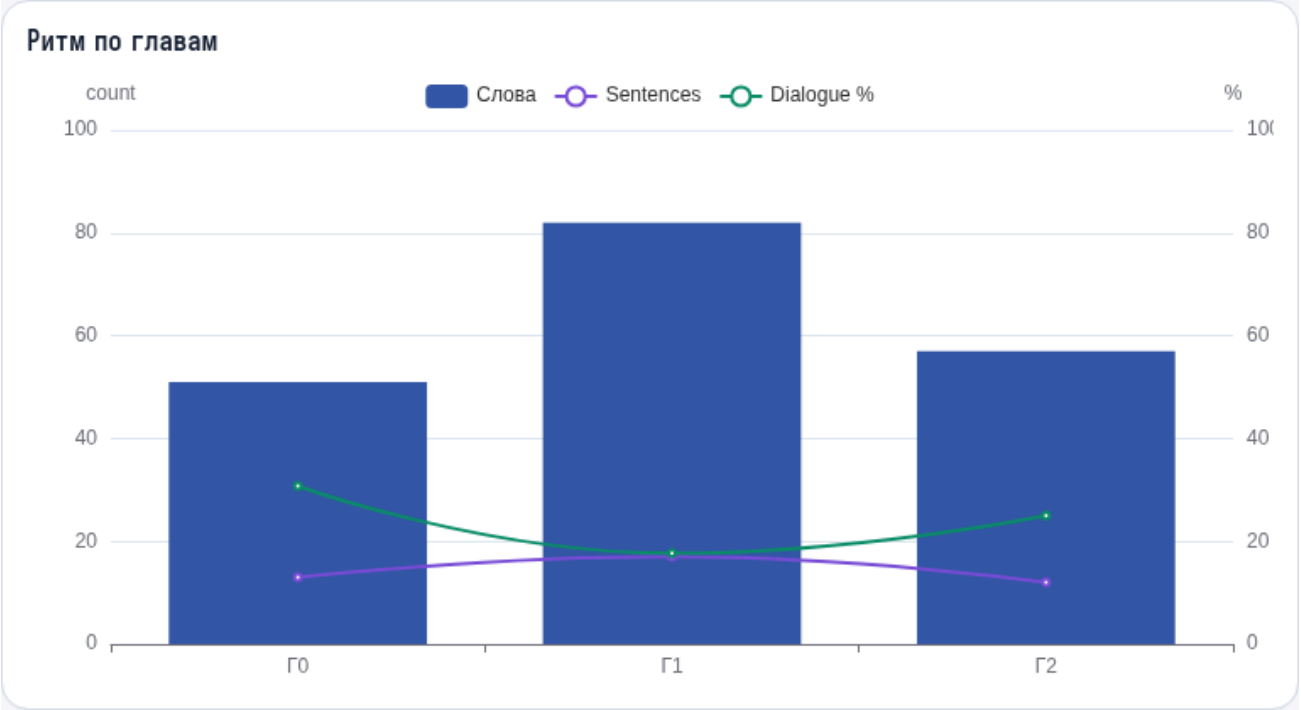

Диаграмма показывает плотность текстовой активности по главам и помогает находить пики динамики.

Тональность по главам

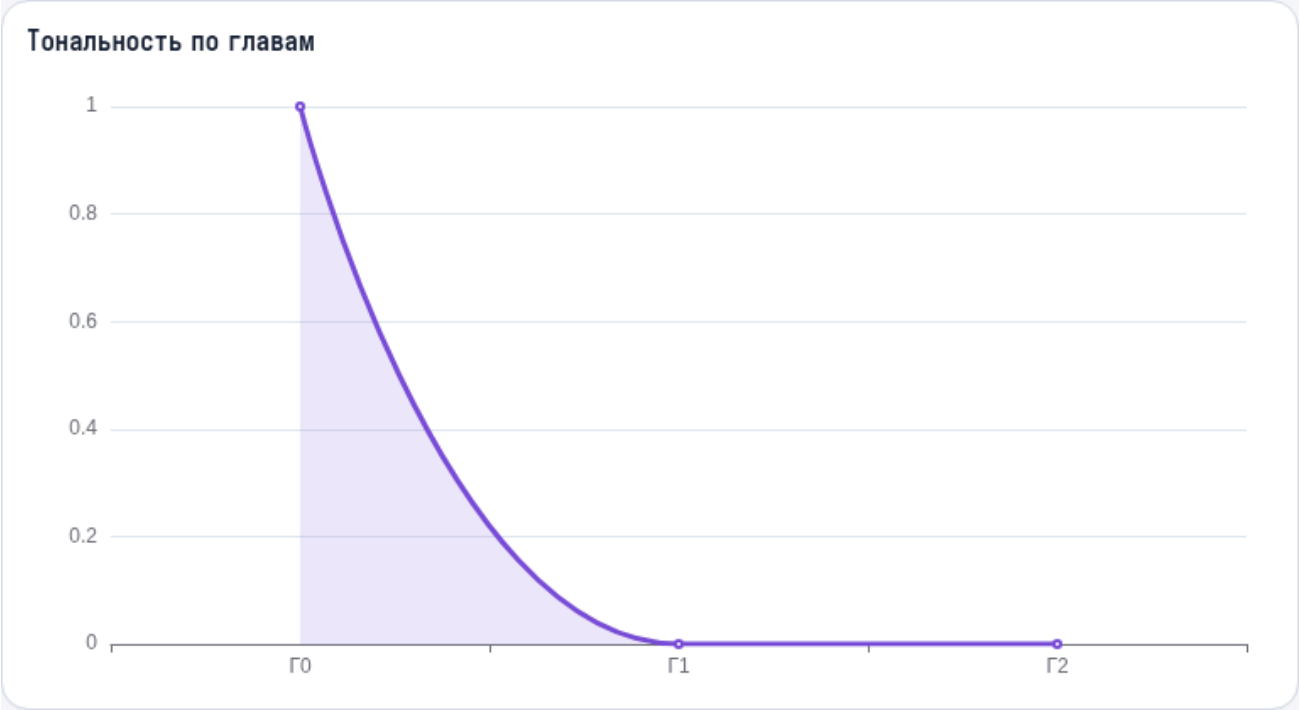

Линейный график показывает изменение тональности по главам. Это приближенная оценка, но она помогает увидеть эмоциональные сдвиги.

Сеть персонажей

Граф ко-встречаемости показывает, какие персонажи чаще появляются вместе. По нему видно центральных и второстепенных героев.

Список персонажей

Персонажи

name	occurrences	num_chapters	context_sample
Иван	7	3	gently дул в лицо. Иван шёл по улице и дума
Анна	3	2	ы кто? — Меня зовут Анна. Я здесь новая.
Петр	2	1	ван! — окликнул его Петр. — Здравствуй, Петр
Осень	2	2	шь? — Просто гуляю. Осень красивая.

Таблица показывает найденных персонажей и частоту их упоминаний. Часть расхождений связана с эвристическим выделением имен.

Hapax legomena

Hapax

token	count
gently	1
а	1
аллее	1
была	1
было	1
ветер	1
вещи	1
взгляд	1
вместе	1

Это слова, которые встретились только один раз. Они полезны для изучения редкой лексики и возможных артефактов разметки.

Метаданные прогона

Метаданные прогона

key	value
book_id	test_book
start_time	2026-05-11T18:30:33.264495
end_time	2026-05-11T18:30:33.264530
duration_seconds	0.000035
lang	ru
ner_mode	heuristic
sentiment_mode	lexicon

Файл run_metadata.json фиксирует параметры и время прогона. Это важно для воспроизводимости результатов.

Пунктуация и структура

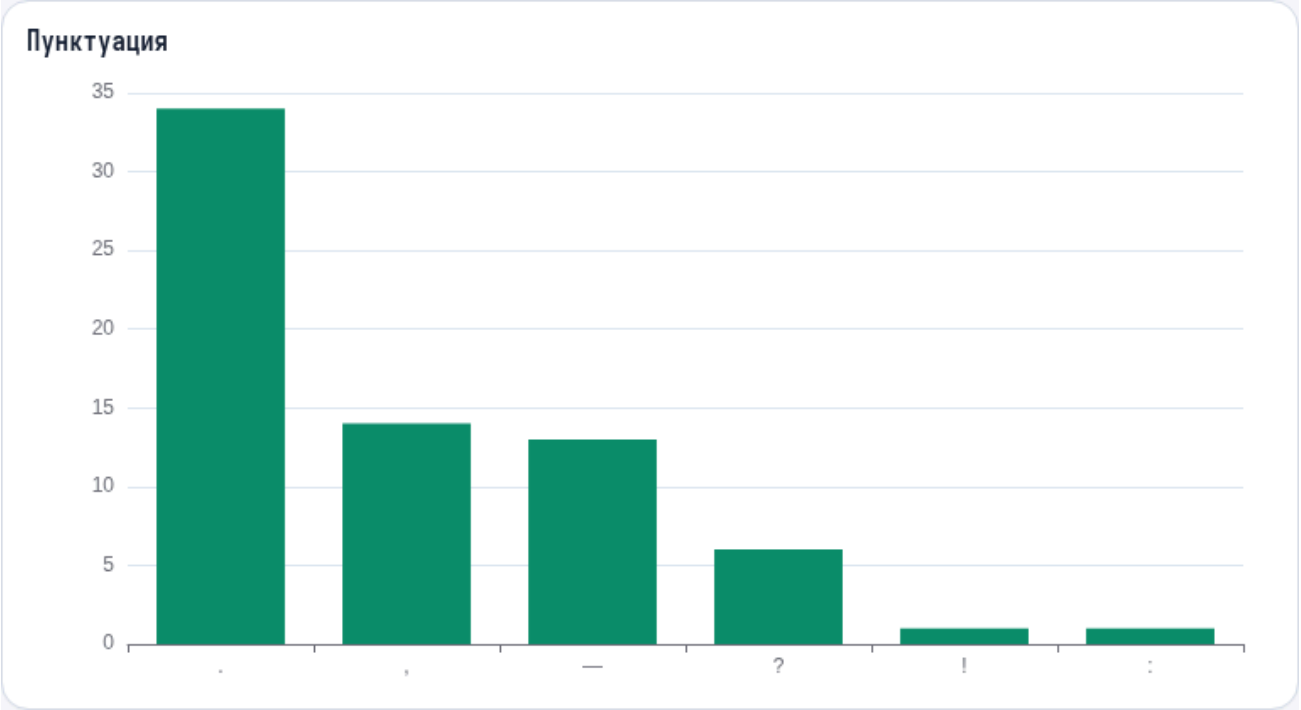

Частоты пунктуации по главам помогают увидеть диалоги, паузы и смену ритма повествования.

Стиль: radar

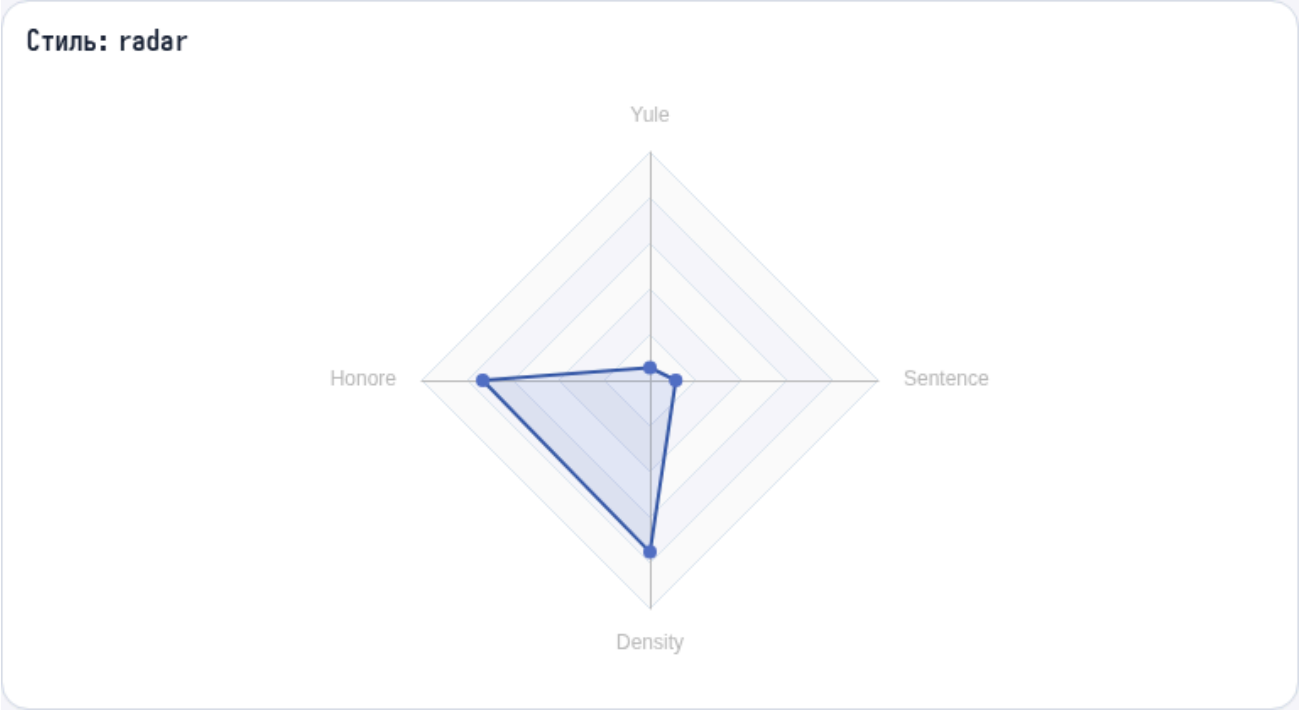

Радар-диаграмма сводит несколько метрик главы в один образ: лексическую плотность, длину предложений и другие признаки стиля.

Главы: words × sentences

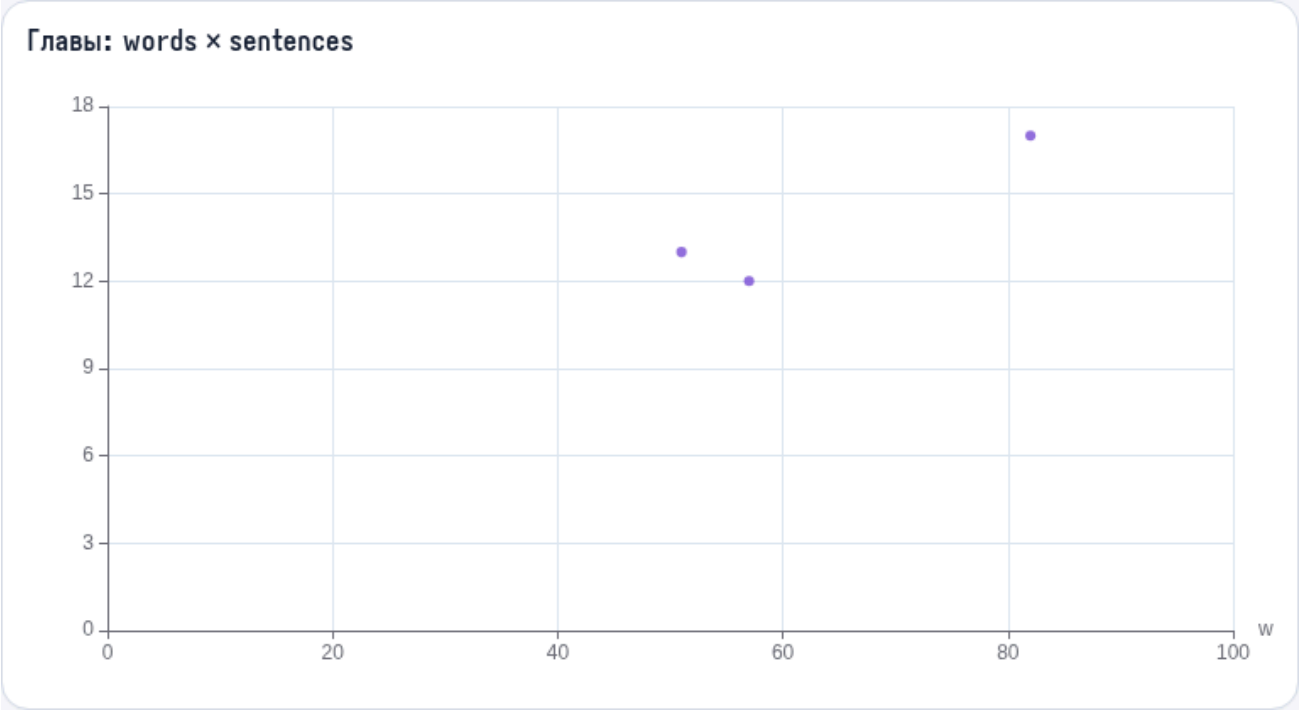

Диаграмма показывает соотношение слов и предложений в главах и позволяет быстро заметить аномалии.

Персонажи × главы

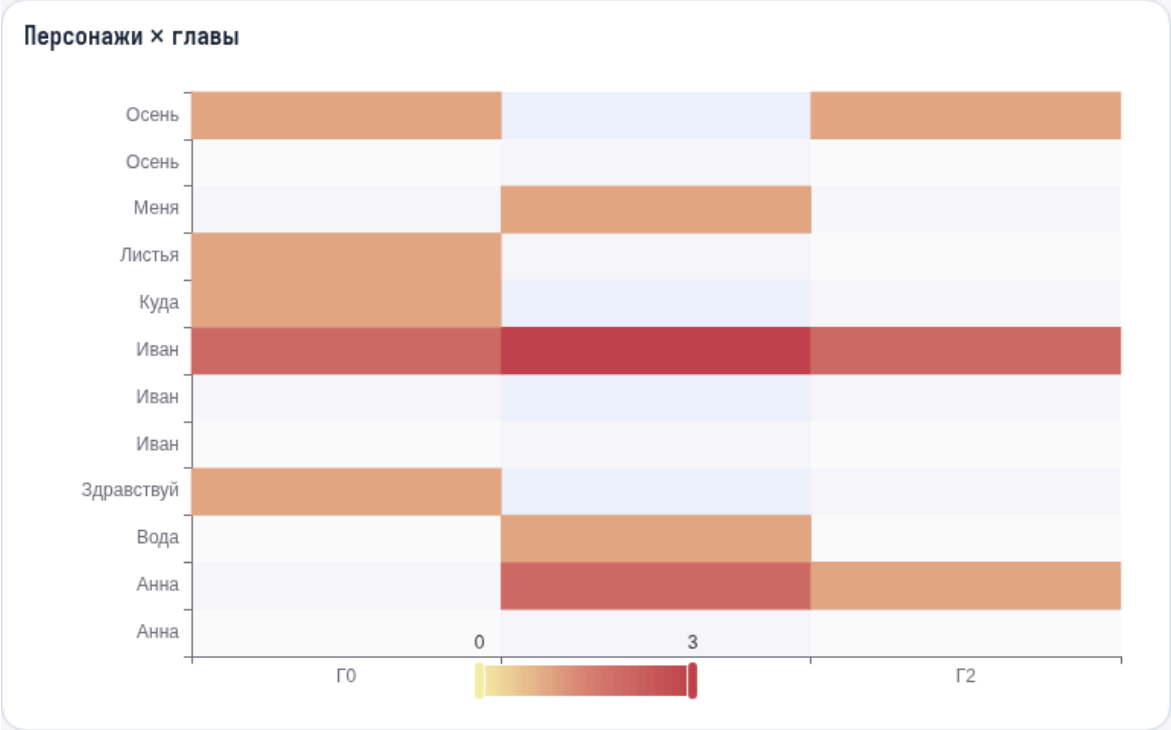

Тепловая карта показывает, где и в каких главах появляются персонажи. Это удобно для отслеживания сюжетных арок.

Токены × главы

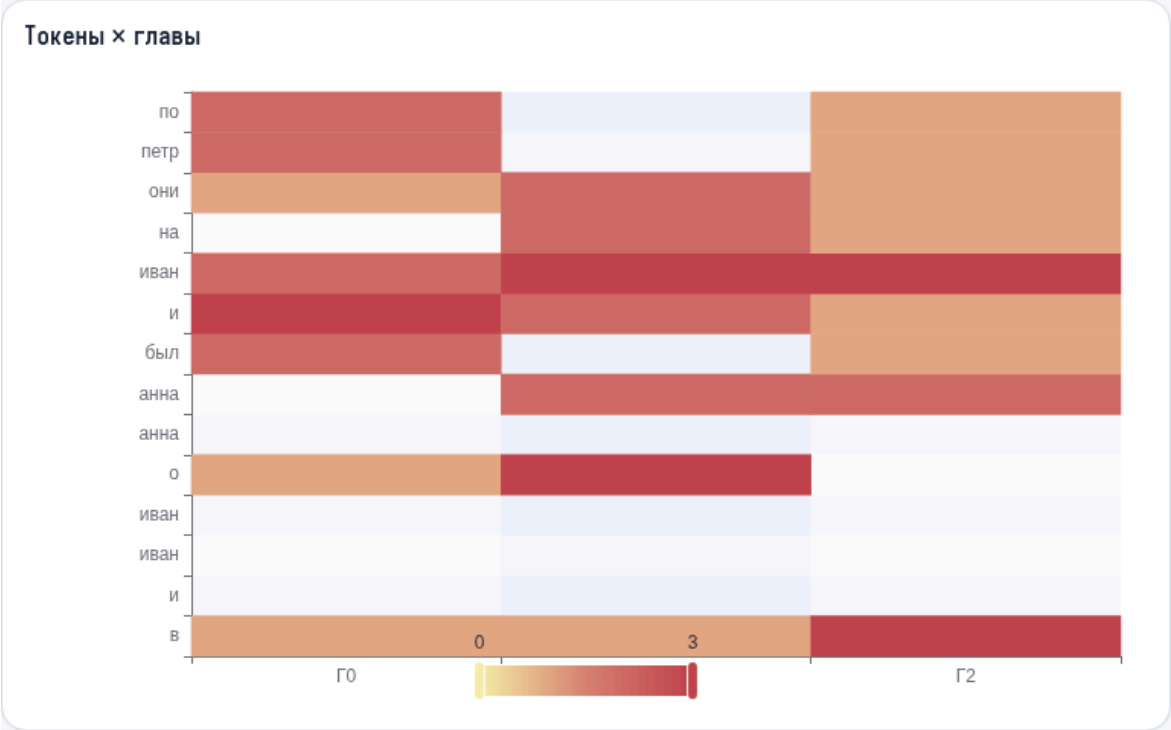

Тепловая карта показывает распределение частот ключевых токенов по главам и помогает увидеть тематические акценты.

Zipf: rank × frequency

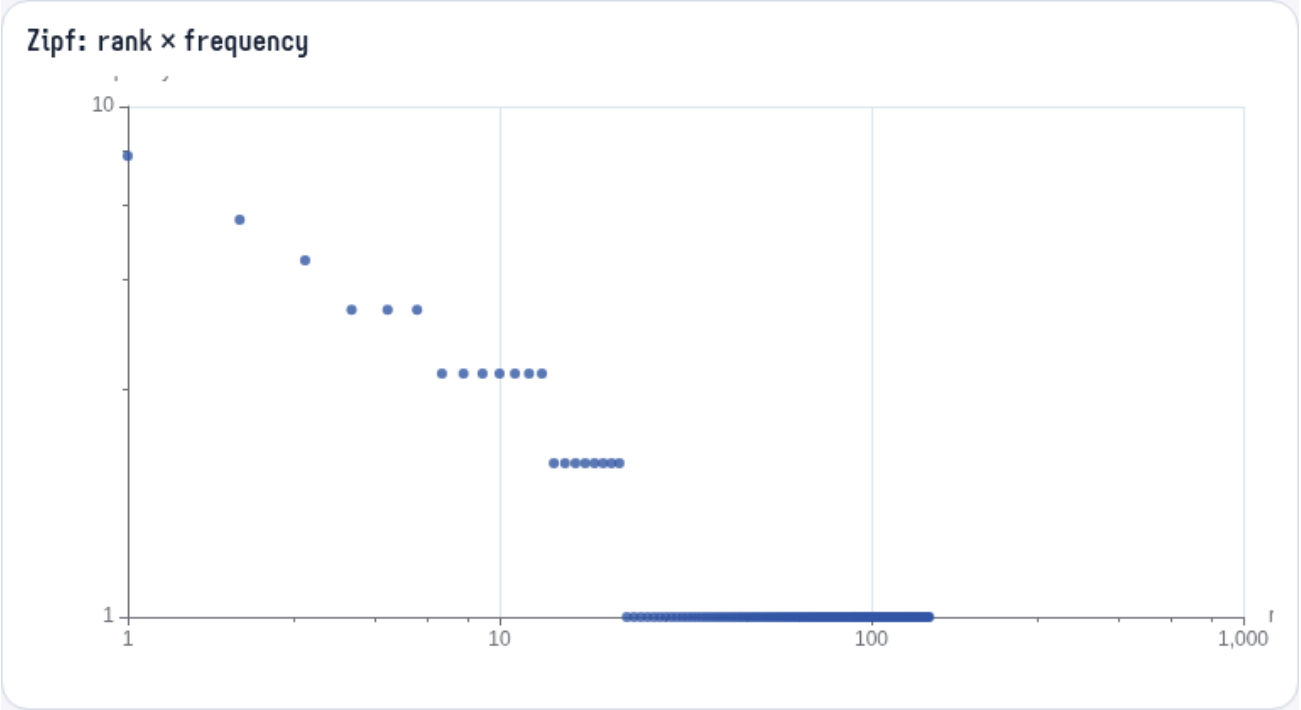

Граф ранга и частоты токенов показывает закон Ципфа и помогает проверить качество токенизации.

Реализация и выводы

Проект показывает полный конвейер: от текста до визуализаций и статической витрины. Все артефакты хранятся в `outputs/<book_id>/` и экспортируются в `site/public/data/`.

Следующие шаги — улучшение выделения именованных сущностей, проверка персонажей, сравнение изданий и масштабирование на корпус.

Итоговый архив и отчет по исследованию

Спасибо за внимание

Вопросы, замечания и дополнительные материалы доступны в репозитории.

Финальная благодарность с книгами и роботом